

Tugas 1

Analisis

Multivariat

Dipresentasikan oleh:

Benhard Leroy Situmorang

Dataset & Tujuan

Dataset

Dataset: Breast Cancer Wisconsin Dataset

Sumber dataset: Pustaka Python scikit-learn.learn (sklearn.datasets.load_breast_cancer).

Jumlah observasi data: 569

Jumlah variabel fitur: 30


Dataset ini terbagi menjadi dua kategori diagnosis, yaitu Benign (Jinak) dan Malignant (Ganas).



Tujuan Utama

- Mereduksi dimensi data yang memiliki banyak variabel tanpa kehilangan informasi signifikan
- Mengungkap faktor biologis laten tersembunyi
- Mengelompokkan profil pasien secara otomatis tanpa supervisi

Alur Analisis



Data Preprocessing dan Standarisasi

Cek Missing value

```
Jumlah missing value:  
0
```




Standarisasi Data

Standardisasi data itu dibutuhkan karena ada skala variabel yang sangat bervariasi, mengakibatkan hasil tersebut akan menjadi bias. Standardisasi data itu dilakukan dengan Z-score scaling (Formulasi: $Z = (x - \mu) / \sigma$) untuk mendapatkan variabel rata-rata (μ) = 0 dan standar deviasi (σ) = 1.

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mean concave points	mean symmetry	mean fractal dimension	...	worst texture	worst perimeter	worst area	worst smoothness	worst compactness
0	1.097064	-2.073335	1.269934	0.984375	1.568466	3.283515	2.652874	2.532475	2.217515	2.255747	...	-1.359293	2.303601	2.001237	1.307686	2.616665
1	1.829821	-0.353632	1.685955	1.908708	-0.826962	-0.487072	-0.023846	0.548144	0.001392	-0.868652	...	-0.369203	1.535126	1.890489	-0.375612	-0.430444
2	1.579888	0.456187	1.566503	1.558884	0.942210	1.052926	1.363478	2.037231	0.939685	-0.398008	...	-0.023974	1.347475	1.456285	0.527407	1.082932
3	-0.768909	0.253732	-0.592687	-0.764464	3.283553	3.402909	1.915897	1.451707	2.867383	4.910919	...	0.133984	-0.249939	-0.550021	3.394275	3.893397
4	1.750297	-1.151816	1.776573	1.826229	0.280372	0.539340	1.371011	1.428493	-0.009560	-0.562450	...	-1.466770	1.338539	1.220724	0.220556	-0.313395

Hasil PCA

Screeplot



Explained Variance Ratio

PC1 : 44,27%

PC2: 18,97%

Rasio Kumulatif: 63,24%

Penentuan Jumlah PC lebih dari 80% Threshold: 5

PC pertama dengan rasio kumulatif menangkap 84.73% varians data (memenuhi target > 80% Kriteria Kaiser).

Kontribusi Terbesar PCA

Kontribusi Terbesar PC1

```
Top 3 Kontributor Positif Terbesar PC1:  
mean concave points      0.253887  
mean concavity           0.251485  
worst concave points      0.244640  
Name: PC1, dtype: float64
```


Kontribusi Terbesar PC2

```
Top 3 Kontributor Positif Terbesar PC2:  
mean fractal dimension    0.366343  
fractal dimension error    0.279718  
worst fractal dimension    0.275013  
Name: PC2, dtype: float64
```

Kesimpulan Substantif:

- PC1 merepresentasikan indeks 'Ukuran dan Kelainan Bentuk Makro Sel'.
- PC2 merepresentasikan indeks 'Kompleksitas Mikro Grafis dan Tekstur Sel'.

Visualisasi Skor PC1 vs PC2



Keterangan:

Biru (Mendekati 0): Malignant / Kanker Ganas

Merah (Mendekati 1): Benign / Tumor Janak

Factor Analysis

Berbeda dengan PCA yang hanya merangkum varians, FA fokus kepada pemodelan varians bersama antar fitur

Berdasarkan visualisasi scree plot PCA, saya menggunakan 4 faktor dengan alasan:

- Banyak korelasi antarvariabel
- Mereduksi struktur data
- Lebih jelas untuk diinterpretasikan tiap variabel

Factor Analysis Loading 1 dan 2

--- Faktor Loadings Faktor 1 dan Faktor 2 ---

	Factor1	Factor2
mean radius	0.999732	-0.014447
mean texture	0.336187	0.849152
mean perimeter	0.998594	-0.006454
mean area	0.987870	-0.020448
mean smoothness	0.179101	-0.007009
mean compactness	0.518499	0.109635
mean concavity	0.687297	0.105243
mean concave points	0.830026	0.047213
mean symmetry	0.156826	0.057244
mean fractal dimension	-0.299647	0.062375
radius error	0.685772	-0.015101
texture error	-0.087800	0.458236
perimeter error	0.681918	-0.006758
area error	0.741159	-0.033244
smoothness error	-0.216649	-0.001341
compactness error	0.217306	0.096186
concavity error	0.203005	0.053099
concave points error	0.383770	-0.021604
symmetry error	-0.098608	-0.041974
fractal dimension error	-0.033518	0.022237
worst radius	0.971419	0.062276
worst texture	0.310539	0.949034
worst perimeter	0.968159	0.070234
worst area	0.943593	0.056473
worst smoothness	0.129310	0.207074
worst compactness	0.425372	0.257456
worst concavity	0.537678	0.227132
worst concave points	0.752114	0.144240
worst symmetry	0.171717	0.199811
worst fractal dimension	0.019364	0.242340

Faktor loading 1 yang terdominasi

- Mean Radius
- Mean Parameter
- Mean Area
- Worst Radius

Penamaan Faktor: Ukuran/Morfologi Tumor

Faktor loading 2 yang terdominasi

- Mean Texture
- Worst Texture
- Texture Error
- Worst Compactness

Penamaan Faktor: Tekstur Tumor

Penamaan faktor didasarkan pada variabel dengan loading relatif tinggi.

Factor Analysis Loading 3 dan 4

```
--- Faktor Loadings Faktor 3 dan Faktor 4 ---
              Factor3    Factor4
mean radius    -0.013783  0.003769
mean texture    0.028920  0.110985
mean perimeter  0.032911 -0.031207
mean area       0.053941  0.066555
mean smoothness 0.527872 -0.399795
mean compactness 0.594278 -0.559624
mean concavity  0.520077 -0.392982
mean concave points 0.391221 -0.286720
mean symmetry   0.519271 -0.332473
mean fractal dimension 0.671359 -0.517583
radius error    0.604129  0.382369
texture error    0.300341  0.275147
perimeter error  0.628354  0.325682
area error       0.492596  0.375562
smoothness error 0.476635  0.069413
compactness error 0.622776 -0.415373
concavity error  0.538209 -0.332179
concave points error 0.558483 -0.222998
symmetry error   0.488475  0.043973
fractal dimension error 0.608618 -0.308650
worst radius     0.063835  0.008647
worst texture    -0.015183  0.014089
worst perimeter  0.111423 -0.034772
worst area       0.119493  0.077189
worst smoothness 0.369728 -0.475274
worst compactness 0.409035 -0.652398
worst concavity  0.386501 -0.575020
worst concave points 0.301399 -0.444873
worst symmetry   0.246740 -0.471485
worst fractal dimension 0.482632 -0.675476
```

Faktor loading 3 yang terdominasi

- Mean Fractal Dimension
- Perimeter Error
- Compactness Error
- Fractal Dimension Error

Penamaan Faktor: Variabilitas Pengukuran

Faktor loading 4 yang terdominasi

- Worst Fractal Dimension
- Worst Compactness
- Worst Concavity
- Mean Compactness

Penamaan Faktor: Kompleksitas Bentuk Sel

Penamaan faktor didasarkan pada variabel dengan loading relatif tinggi.

Interpretasi Faktor

Faktor 1 (Ukuran/Morfologi Tumor)

Mengelompokkan variabel dimensi dasar seperti area, radius, dan perimeter secara terintegrasi

Faktor 2 (Tekstur Tumor)

Menarik beban korelasi kuat dari variabel smoothness dan kelunakan sel.

Faktor 3 (Variabilitas Pengukuran)


Merepresentasikan tingkat kecekungan, titik cekung, dan deformasi spasial inti sel.

Faktor 4 (Kompleksitas Bentuk Sel)

Berfokus pada stabilitas tekstur dan nilai deviasi warna abu-abu pada citra digital sel.

Clustering Analysis

Evaluasi Jumlah Kluster (Skor Elbow vs Silhouette)



Jumlah K = 2 (Dilihat dari grafik Elbow vs Silhouette)

Anggota Kluster: Pasien Kluster 0 dan Pasien Kluster 1

Cluster Profiling

- Jumlah Anggota tiap Klaster sama Profil

```
Jumlah Anggota tiap Cluster:
```

```
Cluster
```

```
0      375
```

```
1      194
```

```
Name: count, dtype: int64
```

```
Profil Rata-Rata Geometri Utama Per Cluster:
```

```
          mean radius  mean texture  mean area
```


```
Cluster
```

```
0          12.426691      18.262427  486.772267
```

```
1          17.414536      21.275258  979.857216
```

Cluster Profiling

- Visualisasi Data



Keterangan:

Kuning: Mendekati Klaster ID 1

Ungu: Mendekati Klaster ID 0

Comparison

Metode	Fokus	Output Utama	Insight
Principal Component Analysis (PCA)	Reduksi dimensi	PC & varians	Dimensi utama varians
Factor Analysis	Faktor laten tersembunyi	Faktor loadings	Variabel yang bergerak sama
Clustering (K-Means)	Pengelompokan objek	Cluster & profile	Kelompok observasi yang mirip

Ketiganya komplementer: PCA melihat dimensi, FA melihat struktur laten, clustering melihat kelompok observasi.

Key Insight

Berikut adalah key insight yang bisa didapatkan dari analisis tersebut:

- Analisis ini dapat mereduksi dimensi yang banyak tanpa kehilangan esensi informasi dan memudahkan interpretasi dan evaluasi datanya.
- PC1 berfungsi sebagai pemisah linear alami yang sangat kuat.
- Factor Analysis berguna untuk merangkum berbagai variabel tersebut menjadi 4 faktor utama.
- Analisis Clustering dapat menentukan jumlah klaster yang sesuai untuk mengendalikan dualitas klinis tumor secara natural tanpa bantuan awal label dokter

Keterbatasan Analisis

- **Keterbatasan**

1. PCA sangat dipengaruhi oleh skala jika tidak distandarisasi
2. Hasil clustering mudah berubah berdasarkan perubahan metode preprocessing
3. Factor Analysis dibutuhkan interpretasi subjektif terhadap loading

- **Kesimpulan**

1. Analisis tersebut berhasil menginterpretasikan informasi secara lengkap dalam mereduksi dimensi
2. PCA, FA, dan clustering memberikan insight berbeda tetapi saling melengkapi
3. Analisis ini dapat memberi rekomendasi yang sesuai kepada ahli klinis



Sesi Tanya Jawab

**Terima
Kasih**

