



TUGAS 2 ANALISIS MULTIVARIAT ANALISIS DISKRIMINAN

Dipresentasikan oleh: Benhard Leroy Situmorang

DATA YANG DIGUNAKAN

	A	B	C	D	E	F	G	H	I	J	K	L
1	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
2	40	M	ATA	140	289	0	Normal	172	N	0	Up	0
3	49	F	NAP	160	180	0	Normal	156	N	1	Flat	1
4	37	M	ATA	130	283	0	ST	98	N	0	Up	0
5	48	F	ASY	138	214	0	Normal	108	Y	15	Flat	1
6	54	M	NAP	150	195	0	Normal	122	N	0	Up	0
7	39	M	NAP	120	339	0	Normal	170	N	0	Up	0
8	45	F	ATA	130	237	0	Normal	170	N	0	Up	0
9	54	M	ATA	110	208	0	Normal	142	N	0	Up	0
10	37	M	ASY	140	207	0	Normal	130	Y	15	Flat	1
11	48	F	ATA	120	284	0	Normal	120	N	0	Up	0
12	37	F	NAP	130	211	0	Normal	142	N	0	Up	0
13	58	M	ATA	136	164	0	ST	99	Y	2	Flat	1
14	39	M	ATA	120	204	0	Normal	145	N	0	Up	0
15	49	M	ASY	140	234	0	Normal	140	Y	1	Flat	1
16	42	F	NAP	115	211	0	ST	137	N	0	Up	0
17	54	F	ATA	120	273	0	Normal	150	N	15	Flat	0
18	38	M	ASY	110	196	0	Normal	166	N	0	Flat	1
19	43	F	ATA	120	201	0	Normal	165	N	0	Up	0
20	60	M	ASY	100	248	0	Normal	125	N	1	Flat	1
21	36	M	ATA	120	267	0	Normal	160	N	3	Flat	1
22	43	F	TA	100	223	0	Normal	142	N	0	Up	0
23	44	M	ATA	120	184	0	Normal	142	N	1	Flat	0
24	49	F	ATA	124	201	0	Normal	164	N	0	Up	0
25	44	M	ATA	150	288	0	Normal	150	Y	3	Flat	1
26	40	M	NAP	130	215	0	Normal	138	N	0	Up	0

Informasi Dataset

Dataset: Heart Failure Prediction Dataset

Sumber: Kaggle

Unit Observasi: 918 pasien

Jumlah variabel fitur: 12

Kelas Target: Heart (Kelas Output: 0:

Normal/Sehat, 1: Penyakit Jantung)

Tujuan Penelitian

- 1.Mengidentifikasi karakteristik klinis pasien
- 2.Membangun dan mengevaluasi performa model LDA dalam mengklasifikasikan status penyakit jantung
- 3.Membangun dan mengevaluasi performa model QDA untuk melihat efektivitas batas keputusan nonlinier pada data klinis
- 4.Membandingkan analisis performa pada kedua model diskriminan mana yang paling bagus dengan metode Stratified 5-Fold Cross-Validation

EKSPLORASI DATASET

Distribusi Kelas

01

Kelas 0: 410 (44,7%)
Kelas 1: 508 (55,3%)

Keperluan Scaling

03

Dataset ini dibutuhkan scaling,
karena terdapat variabel fitur
numerik memiliki rentang
berbeda jauh

Missing Values

02

Dataset tersebut memiliki 0
missing values

PEMODELAN LDA

Karakteristik Batas Keputusan: QDA membentuk garis pemisah linier untuk membedakan kedua kelas dengan asumsi utama bahwa prediktor berdistribusi normal multivariat dan memiliki matriks varians-kovarians yang sama (homoskedastisitas) di seluruh kelompok target.

Hasil Kinerja Model (Test Set)

Accuracy: 89% (Akurasi klasifikasi keseluruhan tinggi)

Precision: 89,5% (Meminimalkan salah vonis sehat menjadi sakit)

Recall: 88,5% (Meminimalkan pasien sakit yang lolos/tak terdeteksi)

F1-Score: 88,5% (Keseimbangan presisi dan recall optimal)

LDA REPORT

	precision	recall	f1-score	support
0	0.91	0.84	0.87	82
1	0.88	0.93	0.90	102
accuracy			0.89	184
macro avg	0.89	0.89	0.89	184
weighted avg	0.89	0.89	0.89	184

PEMODELAN QDA

Karakteristik Batas Keputusan: QDA menghasilkan batas keputusan kuadratik nonlinier dengan perbedaan asumsi utama dari LDA adalah QDA mengizinkan setiap kelompok kelas memiliki matriks varians-kovarians masing-masing (heteroskedastisitas).

Hasil Kinerja Model (Test Set)

Accuracy: 86%

Precision: 86%

Recall: 85%

F1-Score: 86%

QDA REPORT					
		precision	recall	f1-score	support
	0	0.87	0.80	0.84	82
	1	0.85	0.90	0.88	102
	accuracy			0.86	184
	macro avg	0.86	0.85	0.86	184
	weighted avg	0.86	0.86	0.86	184

CROSS VALIDATION (STRATIFIED 5 FOLD)

01 Akurasi CV Mean

LDA: 86,49%

QDA: 84,42%

02 SD Akurasi


LDA: 1,93%

QDA: 2,12%

03 Interpretasi Analisis

Hasil dari validasi sidang menunjukkan performa LDA jauh lebih konsisten dan stabil di berbagai sub-sampel data dibandingkan QDA.

PERBANDINGAN KEDUA MODEL



Interpretasi Hasil

1. Analisis Kesalahan Klasifikasi: Model LDA menghasilkan jumlah kesalahan *False Negative* yang lebih rendah daripada model QDA (13 Vs 16).
2. Fleksibilitas matriks kovarians terpisah pada QDA tidak membantu meningkatkan akurasi, melainkan meningkatkan eror misklasifikasi pada kelas pasien sakit.
3. Visualisasi intensitas warna heatmap mengonfirmasi bahwa pola sebaran prediktor klinis pasien jantung lebih cocok dipetakan menggunakan asumsi homogenitas varians (LDA).

Keterangan Heatmap

- Kiri Atas (True Positive)
- Kanan Atas (False Positive)
- Kiri Bawah (False Negative)
- Kanan Bawah (True Negative)

Semakin gelap birunya, semakin banyak pasien

Rekomendasi Model Akhir: Linear Discriminant Analysis (LDA)

CRITICAL THINKING & KETERBATASAN

1. Apakah training accuracy menjadi dasar utama analisis?

Tidak boleh, karena akurasi pada data training sering kali menipu karena model dapat menghafal noise data (overfitting).

2. Risiko QDA pada sampel kelas kecil

Jika ukuran data per kelas minim, estimasi matriks varians-kovarians individu menjadi bias dan tidak stabil, memicu lonjakan varians model (overfitting parah) atau matriks singular.

3. Keterbatasan Analisis

Kedua model mensyaratkan prediktor kontinu berdistribusi normal. Masuknya variabel kategori hasil dummy encoding (seperti jenis kelamin atau tipe nyeri dada) secara teoritis melanggar asumsi normalitas multivariat ini.

4. Aturan jika hasil sama

Jika performa hampir sama, berdasarkan prinsip Occam's Razor, wajib memilih model yang paling sederhana (LDA), agar model linear lebih mudah diinterpretasikan oleh praktisi medis dan meminimalkan risiko overfitting.

KESIMPULAN AKHIR

Linear Discriminant Analysis (LDA) merupakan model diskriminan terbaik untuk mengklasifikasikan risiko penyakit jantung pada dataset ini, di mana LDA unggul dalam performa akurasi rata-rata Cross-Validation (86.49%), meminimalkan pasien yang berada pada *False Negative*, memiliki sensitivitas medis tertinggi (Recall 93% di Kelas 1), serta tingkat stabilitas parameter yang superior daripada Quadratic Discriminant Analysis (QDA).



TERIMA KASIH

APA ADA
PERTANYAAN?